Minería de Texto

R3-1. Polaridad de reseñas de cine y el problema de la negación
Trabajo en clase (en papel)

Alejandra Bustos Juarez. Carlos Octavio Mendoza Jiménez. Nathalie López Pérez.

3 de noviembre de 2026

Oraciones del ejercicio:

A: «no es buena, es mala» B: «no es mala, es buena»

Convención. Se usa el coseno entre vectores

$$\cos(u, v) = \frac{u \cdot v}{\|u\| \, \|v\|},$$

y, en los vectores binarios, el producto punto es el número de elementos compartidos y $\|v\| = \sqrt{\text{número de elementos del vector}}$. La coma se ignora al construir los n-gramas (como en el ejemplo del ejercicio).

1. La bolsa de palabras no ve el orden

1.1. Vectores BOW de unigramas

Vocabulario de unigramas: $V_1 = \{\texttt{no}, \texttt{es}, \texttt{buena}, \texttt{mala}\}$. Se cuentan las apariciones de cada palabra:

	`no`	`es`	`buena`	`mala`
A: «no es buena, es mala»	1	2	1	1
B: «no es mala, es buena»	1	2	1	1

Tabla 1: Vectores BOW de unigramas de las dos oraciones.

Los dos vectores son idénticos, $\mathbf{a} = \mathbf{b} = (1, 2, 1, 1)$, por lo que

$$\cos(A, B) = \frac{1 \cdot 1 + 2 \cdot 2 + 1 \cdot 1 + 1 \cdot 1}{\sqrt{7}\,\sqrt{7}} = \frac{7}{7} = 1.00.$$

La bolsa de palabras no distingue entre dos oraciones que dicen cosas contrarias, porque solo registra *qué* palabras aparecen y no *en qué orden*.

1.2. Conjuntos de bigramas y coseno binario

$$\text{Bigramas}(A) = \{\texttt{no_es},\ \texttt{es_buena},\ \texttt{buena_es},\ \texttt{es_mala}\},$$
$$\text{Bigramas}(B) = \{\texttt{no_es},\ \texttt{es_mala},\ \texttt{mala_es},\ \texttt{es_buena}\}.$$

El vocabulario es la unión de ambos conjuntos:

$$V_2 = \{\texttt{no_es},\ \texttt{es_buena},\ \texttt{buena_es},\ \texttt{es_mala},\ \texttt{mala_es}\}.$$

	no_es	es_buena	buena_es	es_mala	mala_es
A: «no es buena, es mala»	1	1	1	1	0
B: «no es mala, es buena»	1	1	0	1	1

Tabla 2: Vectores binarios de bigramas de las dos oraciones.

Bigramas compartidos: `no_es`, `es_buena` y `es_mala`, es decir, $A \cdot B = 3$. Cada vector tiene 4 unos, así que $\|A\| = \|B\| = \sqrt{4} = 2$:

$$\cos(A, B) = \frac{3}{2 \cdot 2} = 0.75.$$

2. Marcado de negación

2.1. Aplicación de la regla

Regla: anteponer `NEG_` a cada palabra que sigue a una negación (`no`, `not`, `never`, `n't`) hasta el siguiente signo de puntuación. La negación en sí no se marca, y la coma cierra el alcance.

$$A:\ \text{«no es buena, es mala»} \longrightarrow \{\texttt{no},\ \texttt{NEG_es},\ \texttt{NEG_buena},\ \texttt{es},\ \texttt{mala}\},$$
$$B:\ \text{«no es mala, es buena»} \longrightarrow \{\texttt{no},\ \texttt{NEG_es},\ \texttt{NEG_mala},\ \texttt{es},\ \texttt{buena}\}.$$

Vocabulario (7 elementos): `no`, `NEG_es`, `NEG_buena`, `NEG_mala`, `es`, `buena`, `mala`.

	no	NEG_es	NEG_buena	NEG_mala	es	buena	mala
A	1	1	1	0	1	0	1
B	1	1	0	1	1	1	0

Tabla 3: Vectores binarios con marcado de negación.

Comparten `no`, `NEG_es` y `es`, es decir, 3 de 5 elementos:

$$\cos(A, B) = \frac{3}{\sqrt{5}\,\sqrt{5}} = \frac{3}{5} = 0.60.$$

Ahora `buena` y `NEG_buena` son atributos distintos, y el clasificador puede darles pesos distintos.

Representación	Coseno entre A y B
Unigramas	1.00 (vectores idénticos)
Bigramas	0.75
Unigramas + marcado de negación	0.60

Tabla 4: Coseno entre las dos oraciones según la representación.

2.2. Dos oraciones propuestas por el equipo (en inglés)

Caso en que la regla funciona.

T_1 : «This movie is not good, but the acting is great.»

T_2 : «This movie is good, but the acting is not great.»

Ambas tienen exactamente las mismas palabras, así que sus unigramas coinciden (cos = 1.00) aunque T_1 elogia la actuación y critica la película, y T_2 hace lo contrario. Con el marcado de negación:

$$T_1 \to \{\texttt{this}, \texttt{movie}, \texttt{is}, \texttt{not}, \texttt{NEG_good}, \texttt{but}, \texttt{the}, \texttt{acting}, \texttt{great}\},$$
$$T_2 \to \{\texttt{this}, \texttt{movie}, \texttt{is}, \texttt{good}, \texttt{but}, \texttt{the}, \texttt{acting}, \texttt{not}, \texttt{NEG_great}\}.$$

Comparten 7 de 9 elementos (`this`, `movie`, `is`, `not`, `but`, `the`, `acting`):

$$\cos(T_1, T_2) = \frac{7}{\sqrt{9}\,\sqrt{9}} = \frac{7}{9} \approx 0.78.$$

Por qué funciona: la coma cierra el alcance de la negación justo donde termina la cláusula, de modo que `NEG_good` y `NEG_great` marcan exactamente la palabra negada, y `great` en T_1 y `good` en T_2 quedan sin marcar.

Caso en que la regla falla.

F : «I didn't like the plot but the actors are great» (sin puntuación)

$$F \to \{\texttt{i}, \texttt{didn't}, \texttt{NEG_like}, \texttt{NEG_the}, \texttt{NEG_plot},$$
$$\texttt{NEG_but}, \texttt{NEG_the}, \texttt{NEG_actors}, \texttt{NEG_are}, \texttt{NEG_great}\}$$

Por qué falla (alcance excesivo): la negación solo afecta a «like the plot», pero la regla se detiene únicamente en la puntuación, y «but» no es un signo de puntuación. Así, `great` se convierte en `NEG_great`, un atributo que en el corpus aparece sobre todo en reseñas negativas («not great»), y empuja al clasificador hacia la clase equivocada en una oración cuyo elogio no estaba negado. Una posible mejora es cerrar también el alcance en conectores de contraste (`but`, `however`, `although`).

Otros límites de la regla (para la ronda de análisis de errores).

- *Negaciones fuera de la lista:* «nadie la recomendaría», porque `nadie` niega pero no está en la lista de palabras de negación.
- *Negación que no invierte la polaridad:* «no solo es buena, es excelente» produce `NEG_buena` en una oración muy positiva.
- *Negación que cambia el sentido:* «not bad at all» es positiva aunque contiene `NEG_bad`; el modelo solo puede aprenderlo si la expresión aparece suficientes veces en el corpus.

3. Promedio de embeddings

3.1. Vectores 2D inventados

Un embedding es una *tabla de consulta*: a cada palabra del vocabulario se le asigna un vector, $E : V \to \mathbb{R}^2$. En el ejercicio de papel, el equipo inventa esa tabla (en la parte de Colab los vectores salen de word2vec preentrenado). Para que el ejemplo tenga sentido, se eligen valores coherentes: x_1 funciona como un eje de polaridad (negativo–positivo) y x_2 como un eje de carga evaluativa. Estos ejes son solo ilustrativos, ya que en word2vec real las dimensiones no tienen una interpretación directa.

Palabra	x_1 (polaridad)	x_2 (carga evaluativa)
`no`	-1.0	0.0
`es`	0.0	0.1
`buena`	0.9	0.8
`mala`	-0.9	0.7

Tabla 5: Embeddings 2D inventados para las cuatro palabras.

3.2. Vector promedio de cada oración

El vector de una oración con n palabras es el promedio de los vectores de sus palabras, $\bar{v} = \frac{1}{n}\sum_{i=1}^{n} E(w_i)$. Ambas oraciones tienen $n = 5$ palabras.

$$
\begin{aligned}
\bar{v}_A &= \tfrac{1}{5}\big[E(\texttt{no}) + E(\texttt{es}) + E(\texttt{buena}) + E(\texttt{es}) + E(\texttt{mala})\big] \\
&= \tfrac{1}{5}\big[(-1.0, 0.0) + (0.0, 0.1) + (0.9, 0.8) + (0.0, 0.1) + (-0.9, 0.7)\big] \\
&= \tfrac{1}{5}\,(-1.0,\ 1.7) = (-0.2,\ 0.34),
\end{aligned}
$$

$$
\begin{aligned}
\bar{v}_B &= \tfrac{1}{5}\big[E(\texttt{no}) + E(\texttt{es}) + E(\texttt{mala}) + E(\texttt{es}) + E(\texttt{buena})\big] \\
&= \tfrac{1}{5}\big[(-1.0, 0.0) + (0.0, 0.1) + (-0.9, 0.7) + (0.0, 0.1) + (0.9, 0.8)\big] \\
&= \tfrac{1}{5}\,(-1.0,\ 1.7) = (-0.2,\ 0.34).
\end{aligned}
$$

Como la suma es conmutativa, $\bar{v}_A = \bar{v}_B$ y $\cos(A, B) = 1.00$.

3.3. ¿Qué información se pierde?

- **El orden.** No se sabe qué adjetivo va negado ni qué palabra viene antes de cuál; A y B quedan en el mismo punto aunque A es negativa y B es positiva.
- **El alcance de la negación.** `no` aporta siempre el mismo vector $(-1.0, 0.0)/5$, sin importar a qué palabra afecta; el promedio no puede *invertir* la polaridad de `buena` o `mala`.
- **Cancelación de polaridad.** En x_1, `buena` ($+0.9$) y `mala` (-0.9) se anulan, y el resultado lo domina `no`. El promedio no representa ni una opinión positiva ni una negativa.

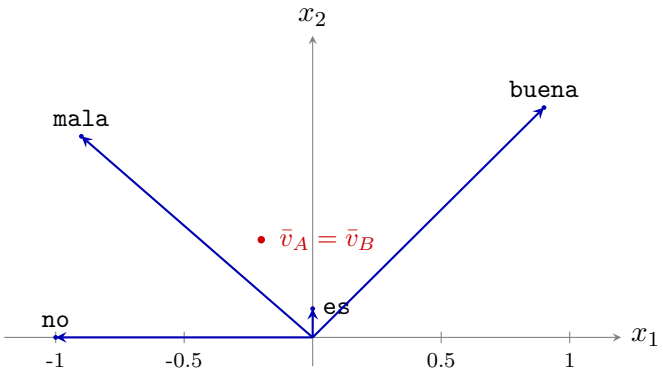


Figura 1: Vectores de las cuatro palabras y vector promedio de ambas oraciones.

- **Una consecuencia para el MLP.** Un clasificador que recibe $\bar{v}$ como entrada asigna la misma predicción a A y a B, así que se equivocará al menos en una de las dos.
- **Longitud y estructura.** Dividir entre n elimina la longitud de la oración, y todas las palabras pesan igual, incluso las funcionales como `es`.

Qué sí se gana respecto a la bolsa de palabras: los vectores capturan similitud semántica (por ejemplo, `good` y `great` quedan cerca), pero el problema del orden y de la negación persiste.

Representación	$\cos(A, B)$
Unigramas (BOW)	1.00
Bigramas	0.75
Unigramas + marcado de negación	0.60
Promedio de embeddings	1.00

Tabla 6: Resumen: el coseno entre «no es buena, es mala» y «no es mala, es buena» según la representación.