POLARIDAD DE RESEÑAS DE CINE

El problema de la negación





Proyecto R3.1 · NLP / Minería de Texto · Dataset IMDb

Alejandra · Carlos · Nathalie

ÍNDICE Y REPARTO

Cuatro actos: del dato crudo a una lectura honesta del error.

ACTO I

DATOS Y BASELINE

Ale · etapas 1–2

ACTO II

REPRESENTACIONES

Nathalie · etapa 3

ACTO III

COMPARACIÓN

Nathalie · Dev

ACTO IV

EXPERIMENTO CONTROL

Carlos / Nathalie

PRESENTA · Equipo

ETAPA 1 · DATOS Y OBJETIVO

Clasificación binaria de sentimiento en reseñas de cine del dataset IMDb.

EL CONJUNTO DE DATOS

50,000 RESEÑAS

Reseñas en inglés etiquetadas según el sentimiento expresado.

DISTRIBUCIÓN DE CLASES

25,000 positivas **25,000 negativas**

Las clases estan balanceadas en el conjunto completo: 25,000 por clase.

OBJETIVO

Predecir si una reseña expresa un sentimiento positivo (1) o negativo (0).

RESEÑA -> **POLARIDAD**

Queremos probar: el significado puede cambiar por el contexto y la negación.

ETAPA 1 · LIMPIEZA Y PARTICIÓN

Preparar el texto y separar los datos evita decisiones basadas en ejemplos de prueba.

1 **TEXTO ORIGINAL**
Reseña cruda

→

2 **LIMPIEZA**
HTML, minúsculas, caracteres

→

3 **REPRESENTACIÓN**
Tokens/vectores

→

4 **PARTICIÓN**
Train / Dev / Test

EJEMPLO DE LIMPIEZA

ANTES

 This Movie Was NOT Good!!!

DESPUES

this movie was not good

División de las 25,000 reseñas originales

TRAIN: 20,000

DEV: 5,000

TEST ORIGINAL 25,000 (RESERVADO)

BASELINE · BOLSA DE PALABRAS + NAIVE BAYES

Un punto de referencia sencillo para comparar las mejoras posteriores.



0.8458
Exactitud

0.8404
F1

0.9198
AUC-ROC

MODELO A · TF-IDF 1–2 GRAMAS + REGRESIÓN LOGÍSTICA

Primera mejora: ponderar términos y añadir pares de palabras, sin marcado explícito de negación.

REPRESENTACIÓN

TF-IDF

Asigna peso a los términos según su frecuencia en la reseña y qué tan comunes son en el corpus.

Unigramas: good

Bigramas: not good

CLASIFICADOR

Regresión logística

Estima la probabilidad de que una reseña sea positiva a partir de las características TF-IDF.

0.9110	**0.9118**	**0.9714**
Exactitud	F1	AUC-ROC

Resultados en Dev · el Modelo A funciona como control para evaluar el efecto de NEG_.

MARCADO DE NEGACIÓN Y MODELO B

Se modifica el preprocesamiento para marcar términos bajo el alcance de una negación.

`“no fue buena, es buenísima”  →  “no NEG_fue NEG_buena es buenísima”`

¿QUÉ CAMBIA?

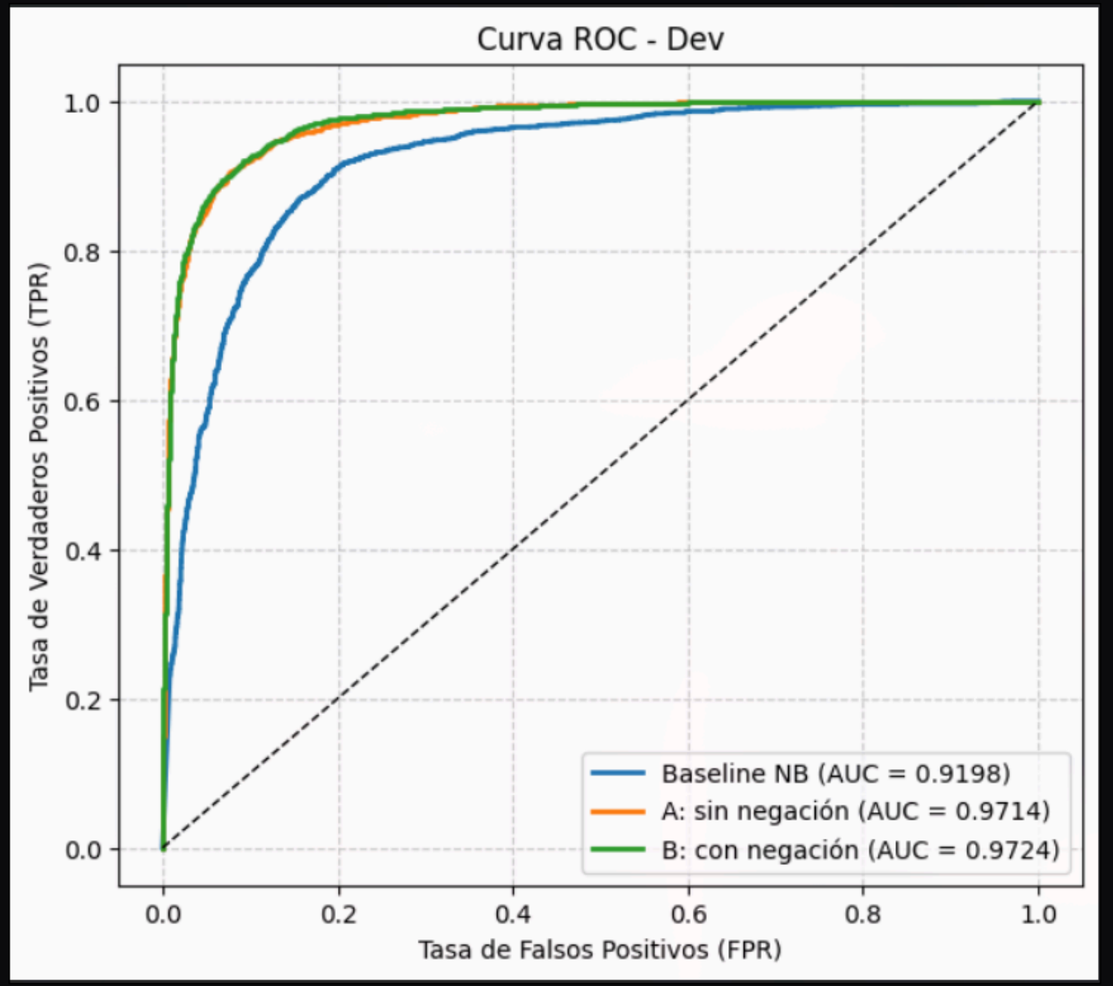
Los términos bajo negación reciben el prefijo NEG_. Así, “good” y “NEG_good” se representan como características distintas.

0.9126	0.9135	0.9724
Exactitud	F1	AUC-ROC

INTERPRETACION DE RESULTADOS

El Modelo A y el Modelo B superan al baseline en las métricas evaluadas. El Modelo B obtiene una mejora pequeña respecto al Modelo A en F1 y AUC-ROC.

Estos resultados sugieren que el marcado explícito de negación aporta una mejora adicional en este conjunto de datos.



ETAPA 3 · WORD2VEC PROMEDIO + MLP

Cambio de representación: de dimensiones dispersas a vectores densos preentrenados.

En lugar de contar palabras (BoW / TF-IDF), representamos cada palabra con un vector denso de 300 dimensiones (Word2vec) y cada reseña como el promedio de los vectores de sus palabras. Sobre esa representación entrenamos un MLP.



La media resume la reseña en un único vector. La MLP aprende fronteras no lineales, aunque el promedio diluye orden y alcance.

RESULTADOS DEL MODELO C

Para realizar la comparación se utilizan 3 métricas:
Exactitud (Accuracy)- Qué proporción de reseñas clasificó correctamente.
F1-score- Equilibrio entre precisión y sensibilidad.
AUC-ROC- Qué tan bien distingue entre reseñas positivas y negativas a diferentes umbrales.

MODELO C

WORD2VEC PROMEDIO + MLP

Representación densa preentrenada, agregación por promedio y clasificador multicapa.

C= menor rendimiento

VS

Modelo	Dev Exactitud	Dev F1	Dev AUC-ROC
Baseline: BoW + Naive Bayes	0.8458	0.8404	0.9198
A: TF-IDF 1-2g + LR (sin negación)	0.9110	0.9118	0.9714
B: TF-IDF 1-2g + LR (con negación)	0.9126	0.9135	0.9724
C: Word2vec promedio + MLP	0.8690	0.8699	0.9415

```
Diferencia C - B en Dev:
  Exactitud : -0.0436
  F1        : -0.0436
  AUC-ROC   : -0.0309
```

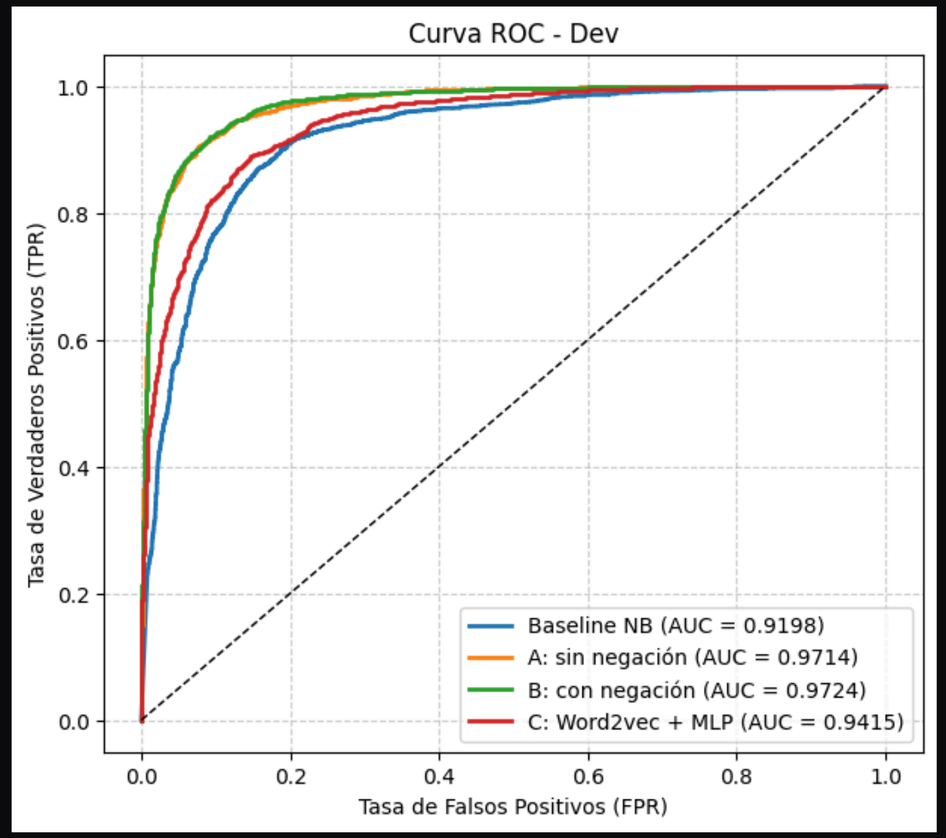
REFERENCIA

MODELO B

TF-IDF 1–2 gramas, marcado NEG_ y Regresión Logística. Comparación en el mismo conjunto Dev.

COMPARACIÓN DE MODELOS EN DEV

Los cuatro modelos, bajo el mismo criterio de evaluación.
1= mejor capacidad de discriminación



MODELO 1

BASELINE

BoW + NB
Frecuencia de palabras

MODELO 2

MODELO A

TF-IDF + RL
Importancia de las palabras y los pares de palabras

MODELO 3

MODELO B

TF-IDF + NEG_ + RL
Estrategia para reconocer la negación

MODELO 4

MODELO C

Word2vec prom. + MLP
Representaciones semánticas preentrenadas y una red neuronal

Word2Vec captura relaciones semánticas entre palabras, pero al promediar sus vectores se pierde información importante, como el orden y el alcance de las negaciones, entonces podemos decir que tiene una mejor clasificación de reseñas el Modelo A y B

PRESENTA · Nathalie

EXPERIMENTO CONTROL

OBJETIVO: Analizar vecinos más cercanos y analogías en Word2Vec e interpretar pesos más importantes en la Regresión Logística

VECINOS MÁS CERCANOS EN W2V

Palabras	good	bad	terrible	boring
Vecinos	great (0.73) bad (0.72) terrific (0.69) decent (0.68) nice (0.68) excellent (0.64) fantastic (0.64) better (0.61)	good (0.72) terrible (0.68) horrible (0.67) Bad (0.67) lousy (0.66) crummy (0.57) horrid (0.57) awful (0.55)	horrible (0.92) horrendous (0.85) dreadful (0.80) awful (0.75) horrid (0.72) atrocious (0.69) horrific (0.68) bad (0.68)	dull (0.74) uninteresting (0.70) monotonous (0.68) bored (0.65) bland (0.63) tedious (0.63) unexciting (0.62) tiresome (0.61)

EXPERIMENTO CONTROL

OBJETIVO: Analizar vecinos más cercanos y analogías en Word2Vec e interpretar pesos más importantes en la Regresión Logística

Analogías en W2V

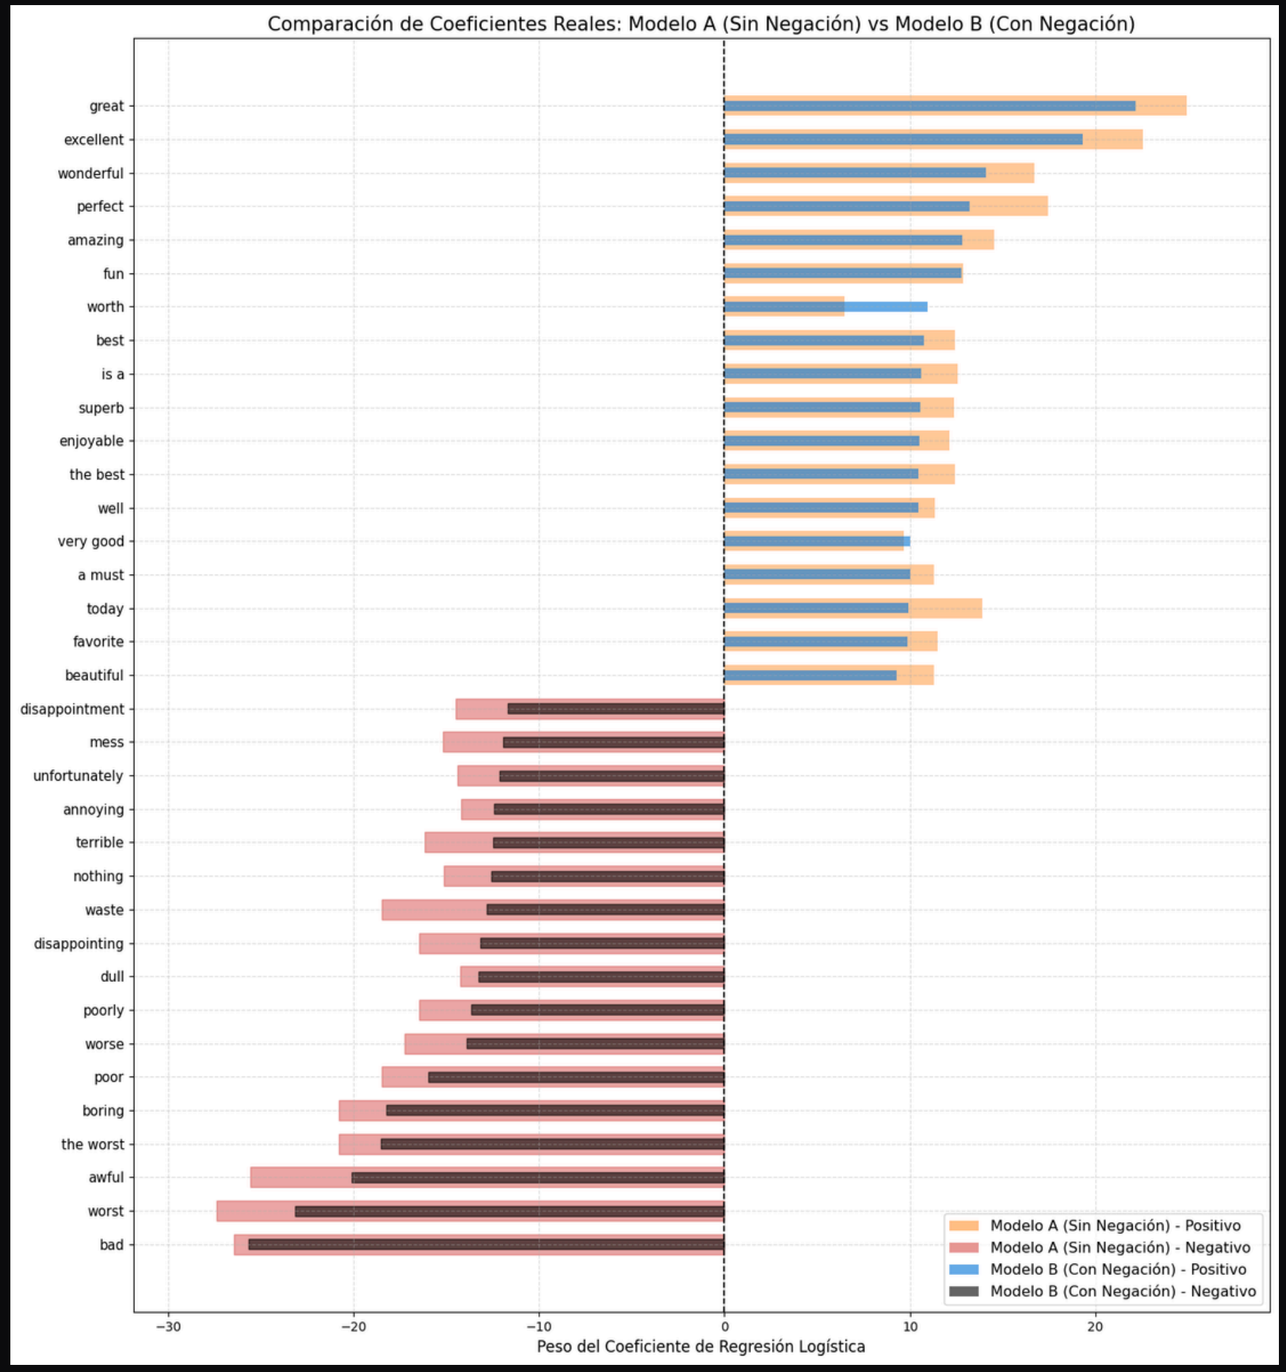
a → b	man → king woman → ?	apple → red banana → ?	man → attractive woman → ?	good → bad great → ?
Analogías	queen (0.71) monarch (0.62) princess (0.59) crown_prince (0.55) prince (0.54)	yellow (0.59) blue (0.52) pink (0.45) purple (0.44) bright_orange (0.42)	unattractive (0.63) alluring (0.61) desirable (0.55) Attractive (0.51) attractive_proposition (0.50)	terrible (0.71) horrible (0.64) unbelievable (0.55) fantastic (0.54) horrendous (0.53)

EXPERIMENTO CONTROL

OBJETIVO: Analizar vecinos más cercanos y analogías en Word2Vec e interpretar pesos más importantes en la Regresión Logística

Pesos en la Regresión Logística

Modelo A
vs
Modelo B



PRESENTA · Carlos / Nathalie

GRACIAS

¿PREGUNTAS?

Alejandra · Carlos · Nathalie